

Controle Estatístico de Qualidade

Breno Cauã Rodrigues da Silva

2025-05-06

Índice

1	Introdução	3
1.1	Ferramentas Básicas do Controle da Qualidade	3
1.1.1	Estratificação	3
1.1.2	Folhas de Verificação	6
1.1.3	Diagrama de Ishikawa	8
2	Gráficos Usuais	10
2.1	Histograma	10
2.1.1	Construção do Histograma com Limites de Especificação	10
2.2	Gráfico de Pareto	11
2.3	Diagrama de Correlação ou Diagrama de Dispersão	13
2.3.1	Construção do Diagrama de Correlação	13
2.3.2	Cálculo do Coeficiente de Correlação Linear de Pearson	16
2.3.3	Teste de Hipótese para o Coeficiente de Correlação Linear de Pearson	16
2.3.4	Conclusão	18
3	Gráficos de Controle	19
3.1	Visão Geral da Inferência Estatística	19
3.1.1	Duas abordagens principais	19
3.1.2	Propriedades dos Estimadores	19
3.2	Estimações do Processo	20
3.2.1	Estimando a Dispersão do Processo	20
3.2.2	Estimando o Nível do Processo	20
3.3	Resumo Geral	20
3.4	Visão Geral de Gráficos de Controle	21
3.4.1	Princípios dos Gráficos de Controle	21
3.4.2	Gráficos de controle para variáveis	21
4	Listas e Exercícios	24
4.1	Lista I	24
5	Lista II	25
	References	26

1 Introdução

Material de apoio para a disciplina de **Controle Estatístico de Qualidade** da *Falculdade de Estatística* (FAEST) da *Universidade Federal do Pará* (UFPA).

Para esta etapa inicial foram usadas as referências:

- Montgomery (2013)
- “Mermaid.js” (s.d.)

1.1 Ferramentas Básicas do Controle da Qualidade

As sete ferramentas da qualidade são técnicas estatísticas simples para resolver problemas na indústria.

- Estratificação
- Folhas de Verificação
- Diagrama de Ishikawa
- Histograma
- Diagrama de Pareto
- Gráfico de Dispersão
- Gráfico de Controle

1.1.1 Estratificação

É uma técnica usada para **separar dados em grupos significativos** para facilitar a análise.

- Permite observar padrões escondidos em dados mistos.
- Ajuda identificar **fontes de variação**.




Figura 1.1: Exemplo de Simulação de Dados Estratificados em Python.




Figura 1.2: Exemplo de Simulação de Dados Estratificados em R.

1.1.1.1 Definição de Estratificação

“Processo de *dividir dados em subgrupos (estratos)* com base em características relevantes como turno, máquina, operador, etc.”

- **Exemplo:** Existe diferença de desempenho entre os turnos?

1.1.1.2 Tipos de Estratificação

- Por **tempo**: turno, dia da semana, mês;
- Por **local**: máquina, setor, linha de produção;
- Por **pessoas**: operador, equipe;
- Por **método** ou **material**.

Tabela 1.1: Exemplos de Tipos de Estratificação.

Tipo	Exemplo
Tempo	Turno
Local	Máquina
Pessoa	Operador
Método	Matéria-prima

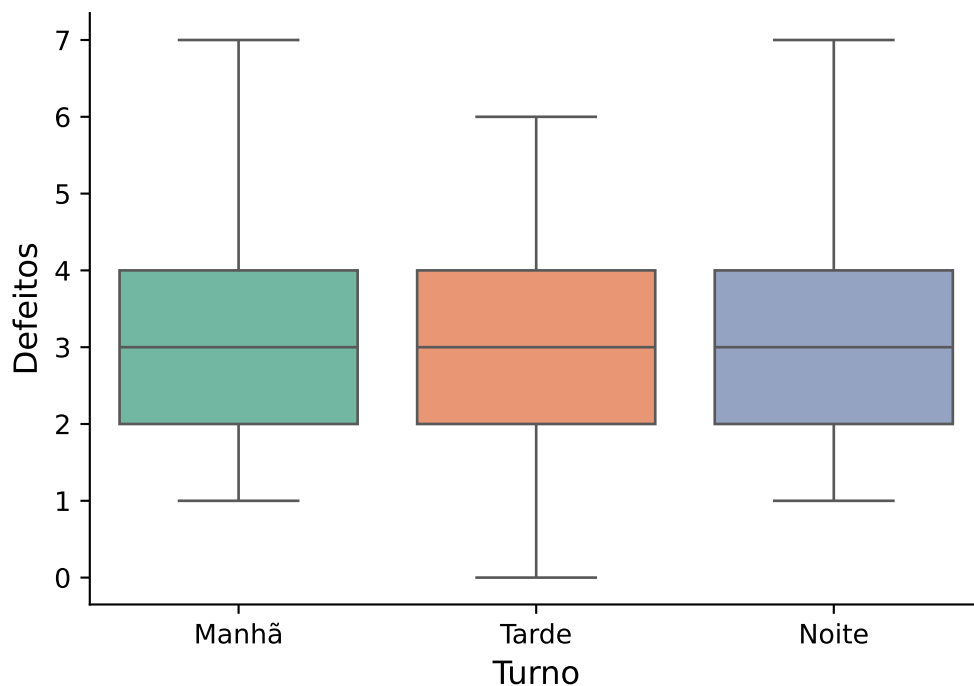


Figura 1.3: Exemplo 2 de Simulação de Dados Estratificados em Python.




Figura 1.4: Exemplo 2 de Simulação de Dados Estratificados em R.

1.1.2 Folhas de Verificação

São formulários usados para **coletar e organizar dados** de forma sistemática.

- Facilitam a visualização e interpretação de dados.
- Podem ser adaptados para diversos propósitos.

1.1.2.1 Definição de Folha de Verificação

“*Documento estruturado para registrar dados observacionais em tempo real.*”

Usada para:

- Contagem de defeitos
- Localização de falhas
- Frequência de ocorrências

Verificação: Distribuição do Processo de Produção

Verificação: Item Defeituoso

Verificação: Localização de Defeitos

Verificação: Causas de um defeito ou falha

Verificação: Satisfação do Cliente (ex.: questionários de satisfação)

Folha de verificação								
	Dia							
Defeito	1	2	3	4	5	6	7	Total
Arranhão	//				//	///		7
Bolha		///		/	/		/	6
Mancha	/		////		/	//	/	9
Amassado				//		/		3
Total	3	3	4	3	4	6	2	25

Figura 1.5: Exemplo de folha de verificação de defeitos na lataria de um carro.

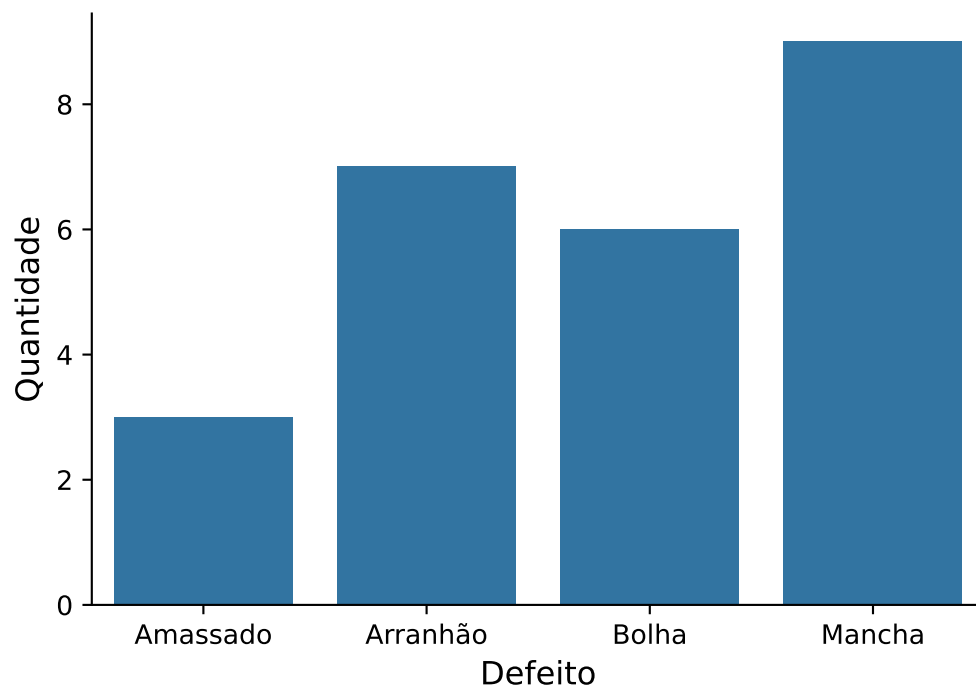


Figura 1.6: Exemplo Gráfico da Folha de Verificação em Python.




Figura 1.7: Exemplo Gráfico da Folha de Verificação em R.

1.1.2.2 Conclusão sobre Folhas de Verificação

Facilitam a **padronização da coleta de dados**
Auxiliam na **identificação de padrões**
São a **base para análises gráficas e estatísticas posteriores**

1.1.3 Diagrama de Ishikawa

Também conhecido como diagrama de causa e efeito ou espinha de peixe.

- Ferramenta para análise de problemas.
- Organiza causas potenciais de um efeito específico.

1.1.3.1 Como construir um Diagrama de Ishikawa

1. Defina claramente o problema (efeito).
2. Trace uma linha horizontal com o problema no final (efeito).
3. Adicione as categorias principais de causa (método, máquina, mão de obra, material, meio ambiente, medição, etc.)
4. Liste causas específicas em cada categoria.




Figura 1.8: Exemplo de diagrama de causa e efeito (Ishikawa).

2 Gráficos Usuais

2.1 Histograma

- O que é um Histograma?
 - Um histograma é uma representação gráfica da distribuição de frequências de dados contínuos.
 - Mostra como os valores se distribuem por intervalos (classes).
 - Ajuda a visualizar:
 - * Tendencia central
 - * Dispersão
 - * Assimetria
 - * Possíveis anomalias

2.1.1 Construção do Histograma com Limites de Especificação

- Limites de especificação:
 - **Limite inferior de especificação (LSE):** menor valor permitido para uma característica de qualidade.
 - **Limite superior de especificação (LIE):** maior valor permitido para uma característica de qualidade.
- Etapas principais:
 1. Coletar dados contínuos (ex.: tempo, peso, medida, etc.).
 2. Definir os intervalos de classe.
 3. Contar quantos dados caem em cada intervalo.
 4. Representar as frequências com barras adjacentes.




Figura 2.1: Exemplo de Histograma com Limites de Especificação em Python.




Figura 2.2: Exemplo de Histograma com Limites de Especificação em R.

- Quando a maioria dos dados está entre LIE e LSE **Processo Capaz.**
- Quando muitos dados estão fora dos limites **Processo Não Capaz.**

2.2 Gráfico de Pareto

É um gráfico de barras que **ordena as causas ou categorias em ordem decrescente de frequência.**

- Baseado no Princípio de Pareto (80/20)
- 80% dos resultados provêm de 20% das causas
- Ajuda a identificar os principais problemas
- **Exemplo:** Dados Simulados de Defeitos.

Tabela 2.1: Dados Simulados de Defeitos.

Categoria	Freq
Erro A	40
Erro B	25
Erro C	15
Erro D	12
Erro E	8




Figura 2.3: Exemplo do Gráfico de Pareto em Python.




Figura 2.4: Exemplo do Gráfico de Pareto em R.

2.3 Diagrama de Correlação ou Diagrama de Dispersão

2.3.1 Construção do Diagrama de Correlação

- **Passos:**
 1. Coletar pares de observações (X , Y);
 2. Plotar os pontos em um gráfico de dispersão;
 3. Analisar visualmente a existência e o tipo de correlação.
- **Correlação Linear Positiva:**
 - Quando uma variável aumenta, a outra também tende a aumentar.
 - Os pontos seguem uma tendência crescente.
- **Correlação Linear Negativa:**
 - Quando uma variável aumenta, a outra também tende a diminuir.
 - Os pontos seguem uma tendência decrescente.




Figura 2.5: Exemplo de Diagrama de Dispersão em Python.




Figura 2.6: Exemplo de Diagrama de Dispersão em R.

- **Ausência de Correlação Linear:**
 - Os pontos não seguem padrão algum.
 - Indica ausência de relação linear.




Figura 2.7: Exemplo de Diagrama de Dispersão (Sem Relação Linear) em Python.




Figura 2.8: Exemplo de Diagrama de Dispersão (Sem Relação Linear) em R.

2.3.2 Cálculo do Coeficiente de Correlação Linear de Pearson

O *Coeficiente de Correlação Linear de Pearson* mede a força e direção da relação linear entre duas variáveis. Tal medida é obtida a partir da expressão:

$$\hat{\rho} = r = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.1)$$

- **Observações Importantes:**

- Varia de -1 a 1 :
 - * 1 : correlação positiva perfeita;
 - * 0 : sem correlação linear;
 - * -1 : correlação negativa perfeita.

2.3.3 Teste de Hipótese para o Coeficiente de Correlação Linear de Pearson

Normalmente, se testa a significância de $\hat{\rho}$ com as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Ausência de associação linear } (\rho = 0); \\ H_1 : \text{Presença de associação linear } (\rho \neq 0). \end{cases} \quad (2.2)$$

Usa-se para testar as hipóteses da Equação 2.2 a seguinte estatística de teste:

$$t_0 = \frac{\hat{\rho}\sqrt{n-2}}{\sqrt{1-\hat{\rho}^2}}, \quad (2.3)$$

que sob a hipótese nula (H_0) segue uma distribuição t_{n-2} . Vejamos o exemplo:

- **Geração do Dados & Visualização Gráfica:**




Figura 2.9: Dados Simulados para Exemplo em Python.




Figura 2.10: Dados Simulados para Exemplo em R.

- **Cálculo do Coeficiente de Correlação:**

Coeficiente de Correlação de Pearson: $r = 0.6424$

Intervalo de Confiança (95%): 0.3671, 0.8142

Coeficiente de Correlação de Pearson: $r = 0.7175$

Intervalo de Confiança (95 %): 0.4818 0.8564

- **Teste de Hipótes para o Coeficiente de Correlação:**

Estatística de Teste (W) = 0.9621

Nível Descritivo (p-value) = 0.3509

Estatística de Teste (W) = 0.9627

Nível Descritivo (p-value) = 0.3630

Estatística de Teste (t) = 4.4353

Graus de Liberdade (df) = 28

Nível Descritivo (p-value) = 0.0001

Shapiro-Wilk normality test

data: x

W = 0.97894, p-value = 0.7966

Shapiro-Wilk normality test

data: y

W = 0.96204, p-value = 0.3488

Estatística de Teste: t = 5.4508

Graus de Liberdade: gl = 28

Valor-p: 0

2.3.4 Conclusão

- São úteis para investigar relação entre variáveis
- Ajudam a detectar tendências visuais
- O coeficiente de Pearson quantifica a força da relação
- Há um teste que verifica a significância estatística dessa relação

3 Gráficos de Controle

3.1 Visão Geral da Inferência Estatística

A **inferência estatística** permite tirar conclusões sobre um processo a partir de uma amostra.

- Estimamos parâmetros populacionais (como média e variância).
- Avaliamos a **variabilidade natural** dos dados.
- Essencial para construir **gráficos de controle** com base em dados amostrais.

3.1.1 Duas abordagens principais

- **Estimação:** Processo de aplicação do *estimador* (fórmula) para se obter *estimativas*.
 - **Pontual:** Cálculo de valores pontuais para parâmetros do processo.
 - **Intervalar:** Cálculo de intervalos de confiança para parâmetros do processo.
- **Teste de Hipóteses:** Decisões sobre mudanças no processo com base em evidência estatística.

3.1.2 Propriedades dos Estimadores

Um estimador é uma função da amostra usada para estimar um parâmetro.

Boas propriedades desejáveis:

1. *Não-viesado:* Valor esperado (médio) do estimador é converge (igual) ao parâmetro verdadeiro, isto é,

$$E[\hat{\theta}] = \theta.$$

2. *Consistência:* A medida que n (tamanho amostral) tende ao infinito, o estimador converge, em probabilidade, ao verdadeiro valor do parâmetro. Isto é, seja X_1, X_2, \dots, X_n uma amostra aleatória de uma variável aleatória X com média θ e variância σ^2 .

Um estimador para θ , é dito consistente se:

$$\lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| > \epsilon) = 0, \forall \epsilon > 0.$$

Em geral, a desigualdade de Chebyshev pode ser usada para verificar essa propriedade:

$$P(|\hat{\theta} - \theta| > \epsilon) \leq \frac{\sigma^2}{n\epsilon^2}.$$

Portanto, à medida que n cresce, a probabilidade de o estimador estar distante do verdadeiro parâmetro θ tende a zero, garantindo sua consistência.

3. *Eficiência*: Possui a menor variância possível entre os estimadores não-viesados. Isto é, seja X_1, X_2, \dots, X_n uma amostra aleatória de uma variável X com parâmetro θ

Um estimador $\hat{\theta}$ é eficiente se sua variância atinge o limite inferior dado por:

$$Var[\hat{\theta}] \geq \frac{1}{I(\theta)},$$

em que $I(\theta)$ é a **Informação de Fisher** expressa por:

$$I(\theta) = -E \left[\frac{\partial^2 L(\theta)}{\partial \theta^2} \right].$$

3.2 Estimações do Processo

3.2.1 Estimando a Dispersão do Processo

A dispersão do processo pode ser estimada usando:

- Desvio padrão amostral (S);
- Amplitude Total (AT);
- Desvio médio absoluto.

3.2.2 Estimando o Nível do Processo

O nível do processo geralmente se refere à média do processo.

- É representado por μ , a média verdadeira da variável de interesse;
- É estimada fazendo uso da distribuição amostral de \bar{X} , isto é, $\bar{X} \sim \text{Normal}(\mu, \sigma^2/n)$.

3.3 Resumo Geral

- A inferência estatística fornece as ferramentas para definir limites e linhas centrais ;
- A precisão da estimativa depende do tamanho e representatividade da amostra ;
- Com base nestes conceitos, constrói-se gráficos de controle como \bar{X} , AT , S . entre outros

3.4 Visão Geral de Gráficos de Controle

Os gráficos de controle são ferramentas gráficas usadas para monitorar processos ao longo do tempo.

- Detectam **variações comuns** (naturais) e **variações especiais** (anomalias).
- Ajudam na **manutenção da qualidade** e na **tomada de decisões**.

3.4.1 Princípios dos Gráficos de Controle

- Baseiam-se em **amostras coletadas periodicamente**;
- Mostram uma **linha central** (LC) representando o comportamento esperado do processo;
- Possuem **limites de controle** (LIC e LSC) que indicam variações aceitáveis;
- Proposto por Shewhart (1926);
- Controlar a variabilidade dos processos.

Proposta geral:

$$\begin{cases} LIC &= \mu_w - 3 \times \sigma_w \\ LC &= \mu_w \\ LSC &= \mu_w + 3 \times \sigma_w \end{cases}$$

Temos que:

$$P(LIC \leq X \leq \mu_w) = \alpha/2$$

e

$$P(\mu_w \leq X \leq LSC) = \alpha/2.$$

Se $X_i \sim \text{Normal}(\mu, \sigma^2)$, então

$$P\left(\frac{\mu_w - 3\sigma}{\sqrt{n}} \leq \bar{X}_i \leq \frac{\mu_w + 3\sigma}{\sqrt{n}}\right) = 0,9973$$

que é equivalente a

$$P\left(-3 \leq \frac{\sqrt{n}(\bar{X}_i - \mu)}{\sigma} \leq 3\right) = 0,9973$$

3.4.2 Gráficos de controle para variáveis

3.4.2.1 Gráficos com valores padrão

- **Variância Conhecida:** Quando se tem conhecimento da variância populacional, usa-se as expressões abaixo:

$$\begin{cases} LIC &= \mu - 3\frac{\sigma}{\sqrt{n}}; \\ LC &= \mu; \\ LSC &= \mu + 3\frac{\sigma}{\sqrt{n}}. \end{cases}$$

Ou, de forma sintetizada:

$$\begin{cases} LIC &= \mu - A\sigma; \\ LC &= \mu; \\ LSC &= \mu + A\sigma. \end{cases}$$

Sendo $A = \frac{3}{\sqrt{n}}$

3.4.2.2 Gráficos com valores tabelados

• Principais gráficos:

- \bar{X} e AT ;
- \bar{X} e S ;
- S^2
- Medições individuais ($n = 1$)

■ APPENDIX VI

Factors for Constructing Variables Control Charts

Observations in Sample, n	Chart for Averages					Chart for Standard Deviations						Chart for Ranges					
	Factors for Control Limits			Factors for Center Line		Factors for Control Limits				Factors for Center Line		Factors for Control Limits					
	A	A_2	A_3	c_4	$1/c_4$	B_3	B_4	B_5	B_6	d_2	$1/d_2$	d_3	D_1	D_2	D_3	D_4	
2	2.121	1.880	2.659	0.7979	1.2533	0	3.267	0	2.606	1.128	0.8865	0.853	0	3.686	0	3.267	
3	1.732	1.023	1.954	0.8862	1.1284	0	2.568	0	2.276	1.693	0.5907	0.888	0	4.358	0	2.574	
4	1.500	0.729	1.628	0.9213	1.0854	0	2.266	0	2.088	2.059	0.4857	0.880	0	4.698	0	2.282	
5	1.342	0.577	1.427	0.9400	1.0638	0	2.089	0	1.964	2.326	0.4299	0.864	0	4.918	0	2.114	
6	1.225	0.483	1.287	0.9515	1.0510	0.030	1.970	0.029	1.874	2.534	0.3946	0.848	0	5.078	0	2.004	
7	1.134	0.419	1.182	0.9594	1.0423	0.118	1.882	0.113	1.806	2.704	0.3698	0.833	0.204	5.204	0.076	1.924	
8	1.061	0.373	1.099	0.9650	1.0363	0.185	1.815	0.179	1.751	2.847	0.3512	0.820	0.388	5.306	0.136	1.864	
9	1.000	0.337	1.032	0.9693	1.0317	0.239	1.761	0.232	1.707	2.970	0.3367	0.808	0.547	5.393	0.184	1.816	
10	0.949	0.308	0.975	0.9727	1.0281	0.284	1.716	0.276	1.669	3.078	0.3249	0.797	0.687	5.469	0.223	1.777	
11	0.905	0.285	0.927	0.9754	1.0252	0.321	1.679	0.313	1.637	3.173	0.3152	0.787	0.811	5.535	0.256	1.744	
12	0.866	0.266	0.886	0.9776	1.0229	0.354	1.646	0.346	1.610	3.258	0.3069	0.778	0.922	5.594	0.283	1.717	
13	0.832	0.249	0.850	0.9794	1.0210	0.382	1.618	0.374	1.585	3.336	0.2998	0.770	1.025	5.647	0.307	1.693	
14	0.802	0.235	0.817	0.9810	1.0194	0.406	1.594	0.399	1.563	3.407	0.2935	0.763	1.118	5.696	0.328	1.672	
15	0.775	0.223	0.789	0.9823	1.0180	0.428	1.572	0.421	1.544	3.472	0.2880	0.756	1.203	5.741	0.347	1.653	
16	0.750	0.212	0.763	0.9835	1.0168	0.448	1.552	0.440	1.526	3.532	0.2831	0.750	1.282	5.782	0.363	1.637	
17	0.728	0.203	0.739	0.9845	1.0157	0.466	1.534	0.458	1.511	3.588	0.2787	0.744	1.356	5.820	0.378	1.622	
18	0.707	0.194	0.718	0.9854	1.0148	0.482	1.518	0.475	1.496	3.640	0.2747	0.739	1.424	5.856	0.391	1.608	
19	0.688	0.187	0.698	0.9862	1.0140	0.497	1.503	0.490	1.483	3.689	0.2711	0.734	1.487	5.891	0.403	1.597	
20	0.671	0.180	0.680	0.9869	1.0133	0.510	1.490	0.504	1.470	3.735	0.2677	0.729	1.549	5.921	0.415	1.585	
21	0.655	0.173	0.663	0.9876	1.0126	0.523	1.477	0.516	1.459	3.778	0.2647	0.724	1.605	5.951	0.425	1.575	
22	0.640	0.167	0.647	0.9882	1.0119	0.534	1.466	0.528	1.448	3.819	0.2618	0.720	1.659	5.979	0.434	1.566	
23	0.626	0.162	0.633	0.9887	1.0114	0.545	1.455	0.539	1.438	3.858	0.2592	0.716	1.710	6.006	0.443	1.557	
24	0.612	0.157	0.619	0.9892	1.0109	0.555	1.445	0.549	1.429	3.895	0.2567	0.712	1.759	6.031	0.451	1.548	
25	0.600	0.153	0.606	0.9896	1.0105	0.565	1.435	0.559	1.420	3.931	0.2544	0.708	1.806	6.056	0.459	1.541	

For $n > 25$.

$$\begin{aligned} A &= \frac{3}{\sqrt{n}} & A_3 &= \frac{3}{c_4 \sqrt{n}} & c_4 &\equiv \frac{4(n-1)}{4n-3} \\ B_3 &= 1 - \frac{3}{c_4 \sqrt{2(n-1)}} & B_4 &= 1 + \frac{3}{c_4 \sqrt{2(n-1)}} \\ B_5 &= c_4 - \frac{3}{\sqrt{2(n-1)}} & B_6 &= c_4 + \frac{3}{\sqrt{2(n-1)}} \end{aligned}$$

Figura 3.1: Tabela com fatores para construção dos gráficos de controle para variáveis.

Nota: Iremos utilizar n como o números de características mensuradas (colunas) no processo.

3.4.2.2.1 Gráfico de Controle: \bar{X} e AT

- Quando utilizar:

- Controle da Média e Amplitude;
- Indicados para subgrupos pequenos ($n \leq 10$)

- Expressões para:

- Controle de \bar{X} : $LC_{\bar{X}} = \frac{1}{n} \sum_{i=1}^n \bar{X}_i$, $LIC = LC_{\bar{X}} - A_2 \bar{AT}$ e $LSC = LC_{\bar{X}} + A_2 \bar{AT}$;
- Controle de AT : $LC_{AT} = \bar{AT} = \frac{1}{n} \sum_{i=1}^n AT_i$, $LIC = D_3 \bar{AT}$ e $LSC = D_4 \bar{AT}$;

3.4.2.2.2 Gráfico de Controle: \bar{X} e S

- Quando utilizar:

- Usa Desvio Padrão ao invés da Amplitude;
- Preferido para amostras maiores ($n > 10$).

- Expressões para:

- Controle de \bar{X} : $LC_{\bar{X}} = \frac{1}{n} \sum_{i=1}^n \bar{X}_i$, $LIC = LC_{\bar{X}} - A_3 \bar{S}$ e $LSC = LC_{\bar{X}} + A_3 \bar{S}$;
- Controle de S : $LC_S = \bar{S} = \frac{1}{n} \sum_{i=1}^n S_i$, $LIC = B_3 \bar{AT}$ e $LSC = B_4 \bar{S}$;

3.4.2.2.3 Gráfico de Controle: S^2

- Menos comum;

- Baseado na distribuição Qui-Quadrado (χ^2).

- Expressões:

- Controle de S^2 : $LC_{S^2} = \bar{S}^2 = \frac{1}{n} \sum_{i=1}^n S_i^2$, $LIC = \frac{(n-1)\bar{S}^2}{\chi_{\alpha/2;n-1}^2}$ e $LSC = \frac{(n-1)\bar{S}^2}{\chi_{1-\alpha/2;n-1}^2}$;

- Útil quando se deseja monitorar diretamente a variância do processo.

4 Listas e Exercícios

4.1 Lista I

1. Simule (no R e Python) um conjunto de dados com três turnos de produção e números de defeitos.
 - a. Faça um boxplot para comparar os defeitos entre turnos.
 - b. Comente se a estratificação revela alguma diferença relevante.
2. Monte um diagrama de espinha de peixe para o seguinte problema: “Produto entregue com atraso”. Use papel ou software. Sugestões de Pacote no R: **Mermaid** e **DiagrammeR**.
3. Com base nos dados a seguir, construa um gráfico de Pareto (no papel, R ou Python) e interprete os resultados.

Problemas	Frequência
Risco	80
Mancha	68
Corte	50
Tinta Fraca	45
Erro de Montagem	30

- a. Quais problemas devem ser atacados primeiro?
 - b. Qual o percentual acumulado dos dois problemas mais frequentes?
4. Simule 200 observações com $\mu = 50$ e $\sigma = 10$.
 - a. Crie um histograma.
 - b. Defina limites de especificação mais estreitos: $LIE = 45$ e $LSE = 55$.
 5. Reúna-se com seu grupo faça o seguinte:
 - Colete um conjunto de dados reais (ex.: tempo para executar uma tarefa simples);
 - Classifique os dados usando estratificação (ex.: por turno, grupo, dia, etc.);
 - Construa um histograma, gráfico de Pareto e, se possível um diagrama de Ishikawa para o problema observado;
 - Apresente os resultados com uma breve conclusão.
-

5 Lista II

1. Utilize os vetores abaixo e construa o diagrama de dispersão. $X = \begin{bmatrix} 5 \\ 7 \\ 11 \\ 13 \\ 15 \end{bmatrix}$ e $Y = \begin{bmatrix} 2 \\ 4 \\ 8 \\ 10 \\ 12 \end{bmatrix}$.
 - a. Descreva o tipo de relação entre as variáveis.
 - b. Adicione uma reta de tendência.
 2. Geração de dados com correlação negativa.
 - a. Gere dois vetores de 30 elementos com correlação negativa.
 - b. Construa o gráfico de dispersão.
 - c. Calcule a correlação de Pearson.
 3. Dados reais - `mtcars`. Utilize o conjunto de dados `mtcars`.
 - a. Há relação entre `mpg` (milhas por galão) e `wt` (peso)?
 - b. Faça o gráfico e interprete-o.
 - c. Calcule a correlação de maneira adequada.
 - d. A relação é positiva ou negativa?
 4. Construção de Função - Crie uma função `correlacao_diagnostico()` que:
 - Plote o gráfico de dispersão
 - Calcule o `r`
 - Execute o teste `cor_test()`
 - Apresente o `valor-p` do teste
-

References

- “Mermaid.js”. s.d. <https://csilv7.atlassian.net/wiki/spaces/~71202019d1c3fc8d434cb59c0a9a68051b55c/overview?homepageId=65794>.
- Montgomery, Douglas C. 2013. *Introdução ao Controle Estatístico da Qualidade*. Rio de Janeiro: LTC.
- Shewhart, W. A. 1926. “Quality Control Charts”. *The Bell System Technical Journal* 5 (4): 593–603. <https://doi.org/10.1002/j.1538-7305.1926.tb00125.x>.